

Experimento dirigido: MLP com backpropagation na base Dry Bean

Avaliação de Inteligência Computacional, 2026.2

[Samuel William Silva Almeida
Matrícula: 1631353]

Novembro de 2026

Resumo

Este relatório investiga uma rede MLP treinada por backpropagation na classificação de sete variedades de feijão a partir de 16 atributos geométricos. Foram avaliados inicialização, taxa de aprendizado, momento, topologia, quantidade e qualidade dos dados, atributos e, por fim, a generalização por validação cruzada. A configuração final, com camadas ocultas 80×80, LR = 0,01, momento = 0,7 e 10 atributos de forma, obteve Medida-F macro de $0{,}9436 \pm 0{,}0085$ em validação cruzada com 10 partições. A variação entre partições superou a variação entre as 30 topologias testadas, e a regressão logística ficou a 0,0070 da MLP.

Sumário

1 Introdução e metodologia comum **3**

1.1 Dados 3

1.2 Modelo e pré-processamento 4

1.3 Laço de treinamento 4

1.4 Critérios e métricas 5

2 Questão 1: pesos iniciais e funções de ativação **6**

3 Questão 2: taxa de aprendizado e termo momento **8**

4 Questão 3: número de camadas e de neurônios **12**

5 Questão 4: quantidade e qualidade dos dados de treino **17**

6 Questão 5: quantidade, qualidade e sensibilidade dos atributos **21**

7 Questão 6: validação inicial no conjunto de teste **26**

8 Questão 7: validação cruzada k-fold **29**

9 Conclusão geral **33**

1 Introdução e metodologia comum

A tarefa é classificar grãos de feijão seco em sete variedades (Barbunya, Bombay, Cali, Dermason, Horoz, Seker e Sira) a partir de 16 atributos numéricos extraídos de imagens [1, 2]. Todo o experimento está em `notebooks/mlp_dry_bean.ipynb`, e as tabelas e figuras deste texto são geradas por ele.

O enunciado traz três sobras de versões anteriores: cita o Fashion-MNIST na Questão 1, chama de "Questão 5" e "Questão 6" os relatos das seções 6 e 7, e chama de "Questão 4" a validação inicial. Este relatório segue os títulos das seções e trata a base como Dry Bean em todas as etapas.

1.1 Dados

A base original tem 13.611 exemplos, sem valores ausentes. Havia 68 linhas duplicadas, removidas antes da divisão para que a mesma linha não caísse no treino e no teste ao mesmo tempo (Tabela 1). As classes são desbalanceadas: Dermason tem 3.546 exemplos e Bombay, 522 (Figura 1). Os atributos são muito correlacionados, com $|r|$ de 0,999 entre `Compactness` e `ShapeFactor3`, e de aproximadamente 1,00 entre `Area` e `ConvexArea` (Figura 2).

Tabela 1: Exemplos em cada etapa da preparação. A divisão é estratificada e fixa (70/15/15).

Etapa	Exemplos
Base original	13611
Sem duplicatas	13543
Treino	9479
Validação	2032
Teste	2032

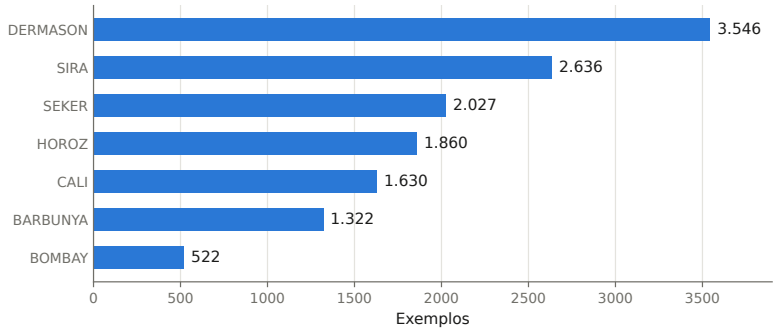


Figura 1: Exemplos por classe, após a remoção de duplicatas.

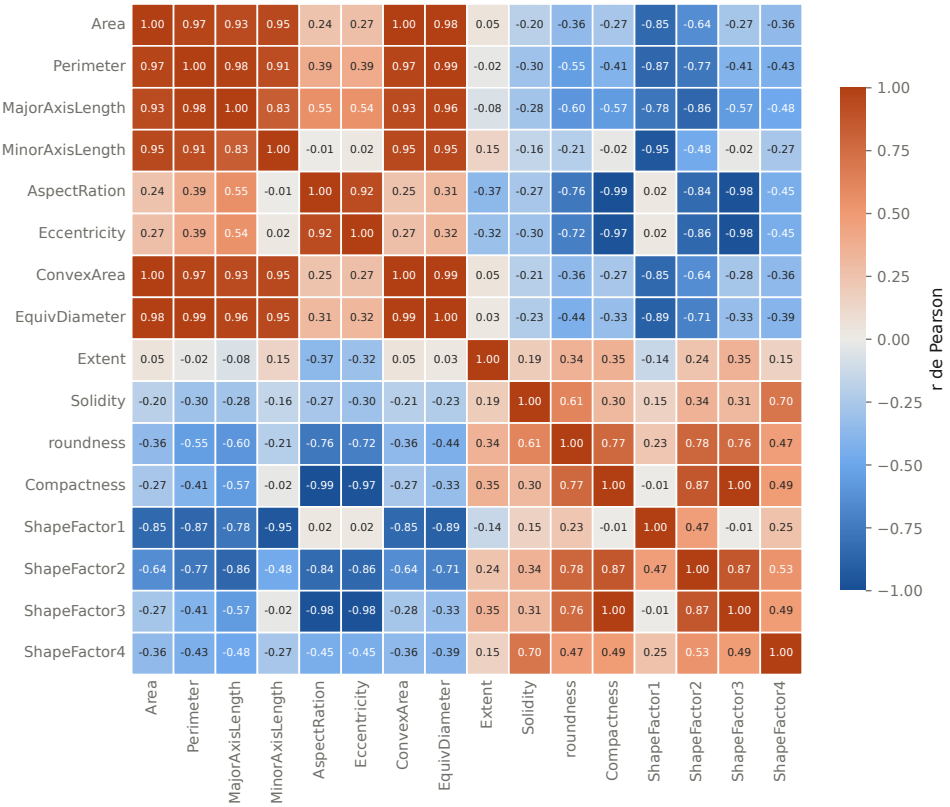


Figura 2: Correlação de Pearson entre os 16 atributos.

1.2 Modelo e pré-processamento

O modelo é o `MLPClassifier` do scikit-learn [3], com SGD, momento clássico (sem Nesterov), lotes de 200 exemplos e regularização L2 com $\alpha = 10^{-4}$, salvo onde indicado. As camadas ocultas usam ReLU; a de saída usa softmax e a perda é a entropia cruzada categórica. A classe aplica softmax e entropia cruzada automaticamente em problemas multiclasse e converte os rótulos internamente em one-hot, cumprindo a codificação recomendada no enunciado. O z-score é ajustado apenas no conjunto de treino de cada execução e aplicado depois aos demais, o que evita vazamento.

1.3 Laço de treinamento

Para registrar métricas a cada época, o treino usa `partial_fit`. A alternativa sugerida na documentação, `warm_start=True` com `max_iter=1`, recria o otimizador a cada chamada e zera a velocidade do momento no início de cada época. Além disso, uma seed inteira repete o embaralhamento em todas as épocas, por isso a seed é passada como um objeto `RandomState`.

A Tabela 2 e a Figura 3 medem esses efeitos. Depois de 200 épocas, a perda com `warm_start` e seed inteira fica 3% acima da obtida com `partial_fit` em LR = 0,01 e 25% acima em LR = 0,1. O efeito é moderado porque cada época tem 48 lotes e, com momento 0,9, a velocidade se recompõe em cerca de 10.

Tabela 2: Perda de treino na época 200 para três laços de treinamento (três seeds).

Configuração	Laço	Perda na época 200	dp
LR=0,01 m=0,9	partial_fit	0,1566	0,0016
LR=0,01 m=0,9	warm_start	0,1600	0,0017
LR=0,01 m=0,9	warm_start, seed inteira	0,1613	0,0031
LR=0,1 m=0,9	partial_fit	0,0949	0,0057
LR=0,1 m=0,9	warm_start	0,1066	0,0007
LR=0,1 m=0,9	warm_start, seed inteira	0,1190	0,0111

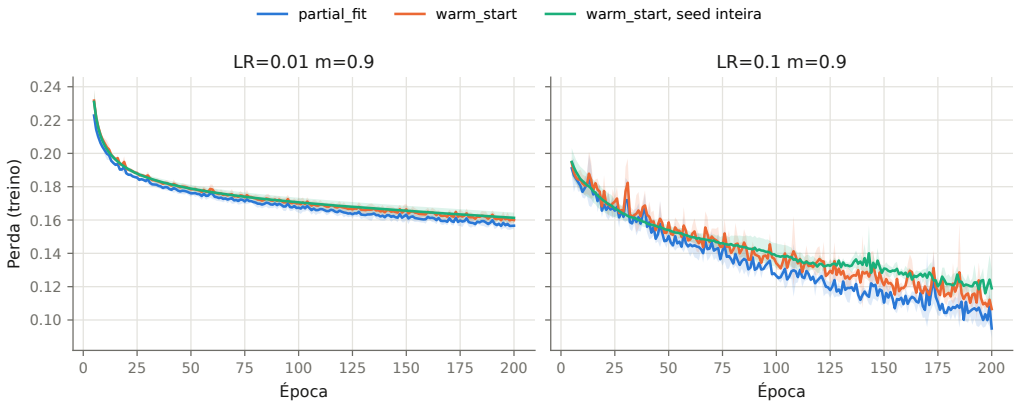


Figura 3: Curvas de perda dos três laços, a partir da quinta época.

1.4 Critérios e métricas

- **Parada:** perda de treino $\leq 0{,}001$ ou limite de épocas. Com os limites usados nas etapas (300 a 500 épocas), esse valor não é atingido, e por isso a velocidade também é medida pelas épocas até a perda de treino chegar a 0,20. A Questão 2 repete sua grade com limite de 5.000 épocas para medir as épocas até 0,001, como pede o enunciado.
- **Perda:** entropia cruzada calculada no conjunto inteiro ao fim de cada época, sem o termo L2.
- **Medida-F, precisão e revocação:** médias macro, em que cada classe pesa igual, inclusive a minoritária.
- **Repetições:** três ou cinco seeds por configuração. Os resultados são média e desvio-padrão (dp).
- **Tempo:** os treinos rodam em paralelo, e os tempos medidos nessa condição não são comparáveis. Uma medição à parte roda um treino por vez, em uma thread, por 30 épocas, e registra o mínimo de cinco repetições intercaladas. Os valores são de uma única máquina e servem para comparar configurações entre si.
- **Uso do teste:** até a Questão 5 toda escolha usa a validação. As Questões 4 e 5 reportam o teste porque o enunciado pede, sem decidir nada com ele.

2 Questão 1: pesos iniciais e funções de ativação

a. Descrição da configuração experimental

A rede tem 16 entradas, duas camadas ocultas com 50 neurônios cada e 7 saídas. Esse tamanho está dentro da faixa explorada na Questão 3 e serve de ponto de partida. As camadas ocultas usam ReLU, que não satura para ativações positivas e costuma convergir bem com a inicialização usada pela classe. A saída usa softmax, que produz uma distribuição de probabilidade sobre as classes. A perda é a entropia cruzada categórica, a escolha padrão para esse tipo de saída.

O otimizador é SGD com momento = 0,9 e LR = 0,01, por até 300 épocas. Usar SGD desde o início mantém esta etapa comparável com a Questão 2. Foram feitos cinco treinamentos com seeds diferentes e, para justificar a ReLU, os mesmos cinco com tanh e logistic. Só o conjunto de treino é usado.

b. Resultados

Tabela 3: Cinco treinamentos com ReLU, no conjunto de treino.

Seed	Perda final	Acurácia final	Medida-F	Épocas
0	0,1476	0,9446	0,9550	300
1	0,1460	0,9458	0,9562	300
2	0,1502	0,9441	0,9545	300
3	0,1483	0,9446	0,9546	300
4	0,1479	0,9463	0,9564	300

Tabela 4: Comparação das funções de ativação (média de cinco seeds).

Ativação	Perda (média)	Perda (dp)	Acurácia (média)	Acurácia (dp)	Épocas até 0,20
relu	0,1480	0,0015	0,9451	0,0009	11,8
tanh	0,1520	0,0008	0,9434	0,0006	16,6
logistic	0,1947	0,0016	0,9283	0,0007	238,8

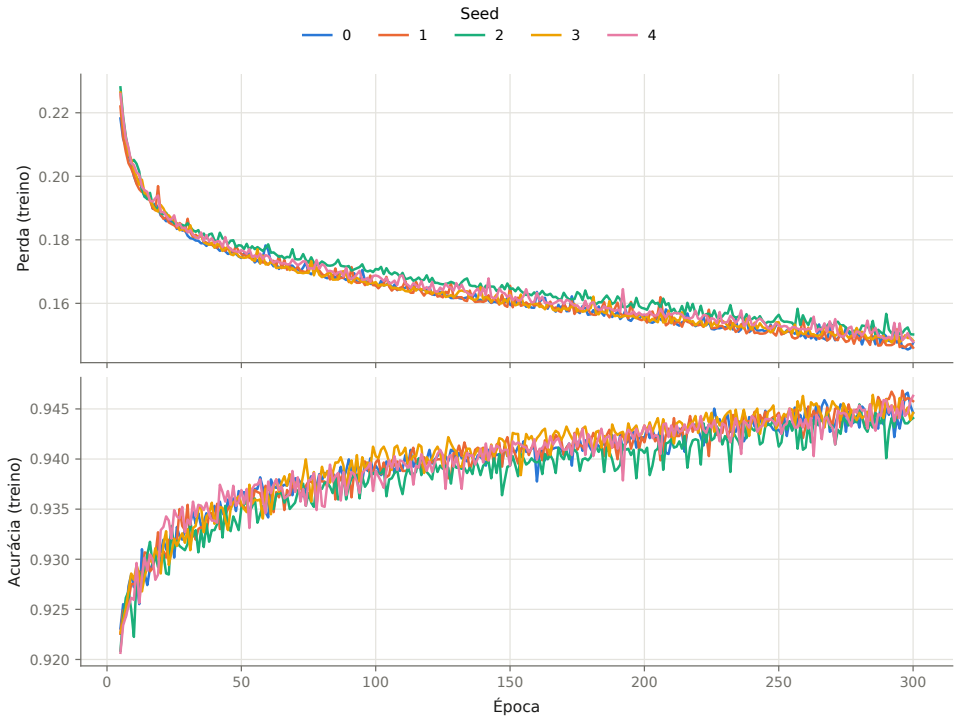


Figura 4: Perda e acurácia de treino com ReLU, por seed, a partir da quinta época.

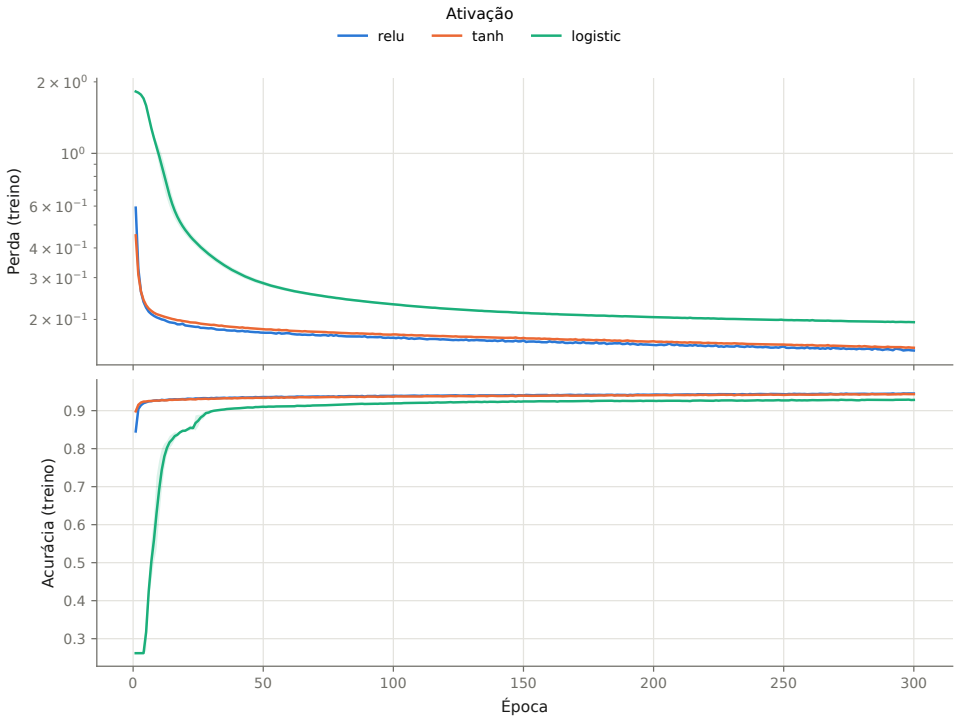


Figura 5: Perda (em escala logarítmica) e acurácia de treino por função de ativação.

c. Análise e discussão

Os cinco treinamentos com ReLU são quase coincidentes: a perda final varia de 0,1460 a 0,1502, e a acurácia de 0,9441 a 0,9463. A inicialização afeta só as primeiras épocas, e o desvio final é

pequeno (0,0015 na perda, 0,0009 na acurácia). As curvas seguem caindo devagar na época 300, com oscilações pequenas, sem sinal de instabilidade.

Quanto à ativação, ReLU e tanh chegam a resultados próximos (perda 0,1480 e 0,1520). A logistic demora muito mais: são 239 épocas até a perda de 0,20, contra 12 da ReLU, e fica com a pior perda final (0,1947). Nas primeiras épocas, sua acurácia fica parada em cerca de 0,26, a proporção da classe majoritária.

Sobre over e underfitting, os dados de treino sozinhos só permitem uma conclusão parcial. Não há underfitting evidente, pois a acurácia passa de 0,94 em todas as seeds. O overfitting não pode ser avaliado sem um conjunto separado, o que é feito a partir da próxima questão.

d. Conclusão da etapa

O modelo aprende os padrões básicos, com acurácia de treino de 0,945. O treinamento é estável em relação aos pesos iniciais, e a ReLU é adequada: converge tão bem quanto a tanh, é muito mais rápida que a logistic e não apresentou nenhuma instabilidade nessa configuração. A topologia 50×50 com ReLU segue como base da Questão 2.

3 Questão 2: taxa de aprendizado e termo momento

a. Descrição do experimento

Foi feita uma grade de 12 combinações: LR em {0,001; 0,01; 0,1; 0,5} e momento em {0,5; 0,7; 0,9}, com três seeds cada. A rede é a da Questão 1 (50×50, ReLU, softmax, entropia cruzada), treinada por SGD com momento clássico. O critério de parada é perda de treino $\leq$ 0,001, com limite de 500 épocas.

O treino atualiza os pesos, e a validação apenas acompanha a generalização. A regra de escolha foi fixada antes de rodar a grade: entre as combinações sem divergência e com perda final de validação até 5% acima da melhor, fica a mais rápida até a perda de treino de 0,20. A tolerância existe porque diferenças tão pequenas ficam perto da variação entre seeds.

Como nenhuma combinação chega a 0,001 em 500 épocas, a mesma grade foi repetida com limite de 5.000 épocas, parando assim que a perda de treino atinge 0,001. Essa segunda rodada mede a velocidade de convergência como o enunciado a define, em épocas até o critério. A escolha de LR e momento continua sendo a da grade de 500 épocas: com 5.000 épocas, a perda final de validação passaria a medir sobretudo o overfitting acumulado.

b. Resultados

Tabela 5: Grade de LR e momento (média de três seeds, em 500 épocas). “Atingiu” e “Divergiu” contam execuções.

LR	Momento	Perda treino	dp treino	Perda val.	Perda val. mín.	F1 val.	Épocas até 0,20	Épocas até 0,001	Atingiu 0,001	Divergiu
0,001	0,5	0,1977	0,0005	0,2130	0,2130	0,9317	447,3	–	0	0
0,001	0,7	0,1889	0,0002	0,2042	0,2042	0,9339	268,7	–	0	0
0,001	0,9	0,1745	0,0011	0,1950	0,1947	0,9352	90,7	–	0	0
0,010	0,5	0,1659	0,0012	0,1919	0,1916	0,9348	45,3	–	0	0
0,010	0,7	0,1584	0,0009	0,1908	0,1899	0,9348	28,0	–	0	0
0,010	0,9	0,1356	0,0022	0,2032	0,1875	0,9350	11,7	–	0	0
0,100	0,5	0,1143	0,0054	0,2406	0,1889	0,9313	6,3	–	0	0
0,100	0,7	0,0885	0,0005	0,3055	0,1883	0,9269	5,7	–	0	0
0,100	0,9	0,0735	0,0265	0,5709	0,1910	0,9244	4,0	–	0	0
0,500	0,5	0,0502	0,0002	0,5351	0,1927	0,9249	4,7	–	0	0
0,500	0,7	0,0547	0,0002	0,6468	0,1961	0,9179	4,3	–	0	0
0,500	0,9	1,8395	0,0031	1,8391	1,8339	0,0593	–	–	0	0

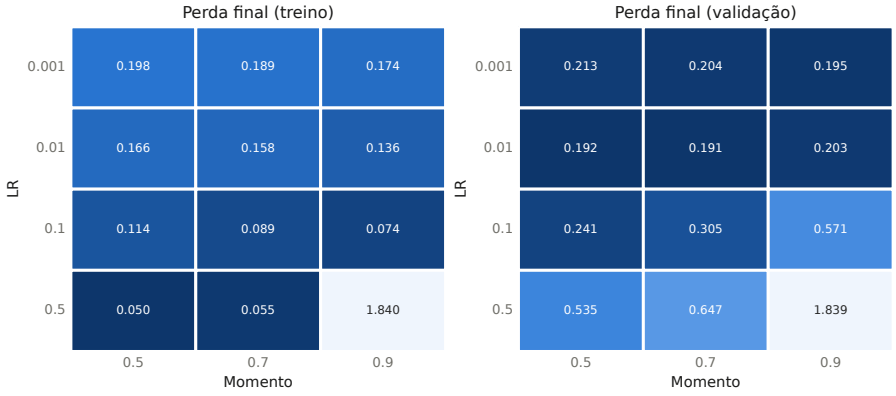


Figura 6: Perda final de treino e de validação. A cor usa escala logarítmica.

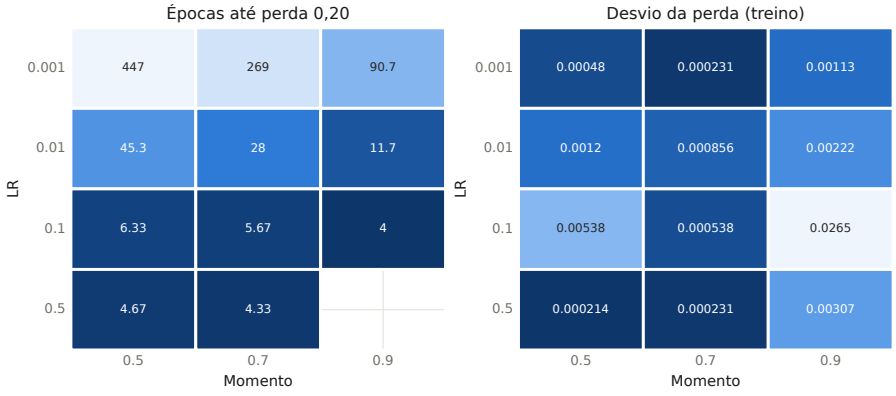


Figura 7: Épocas até a perda de 0,20 e desvio da perda entre seeds. A célula vazia é a combinação que nunca chegou a 0,20.

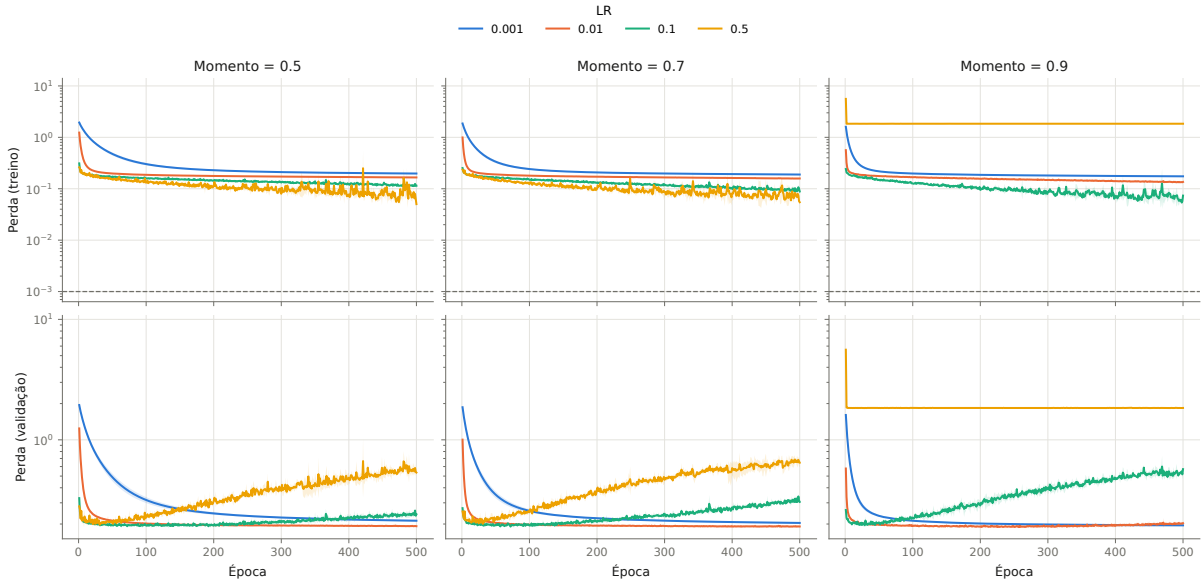


Figura 8: Curvas de perda em escala logarítmica. A linha tracejada marca o critério de 0,001.

A combinação escolhida foi **LR = 0,01 e momento = 0,7**: perda de treino 0,1584, perda de validação 0,1908 e 28 épocas até a perda de 0,20. As candidatas dentro da tolerância foram LR = 0,001 com momento 0,9 (91 épocas), LR = 0,01 com momento 0,5 (45 épocas) e a própria escolhida.

Tabela 6: Grade com limite de 5.000 épocas e parada em perda de treino $\leq$ 0,001 (três seeds). "Épocas até 0,001" é a média entre as seeds que atingiram o critério; as demais colunas são médias das três seeds no fim do treino.

LR	Momento	Atingiu 0,001	Épocas até 0,001	dp épocas	Perda treino	Acur. treino	Perda val.	Perda val. mín.	F1 val.
0,001	0,5	0	–	–	0,1655	0,9393	0,1925	0,1925	0,9354
0,001	0,7	0	–	–	0,1574	0,9419	0,1908	0,1906	0,9345
0,001	0,9	0	–	–	0,1295	0,9520	0,2006	0,1890	0,9364
0,010	0,5	0	–	–	0,0992	0,9641	0,2560	0,1886	0,9316
0,010	0,7	0	–	–	0,0747	0,9728	0,3586	0,1892	0,9286
0,010	0,9	0	–	–	0,0203	0,9937	0,8881	0,1875	0,9209
0,100	0,5	0	–	–	0,0028	0,9994	1,2579	0,1889	0,9210
0,100	0,7	3	4136	730	0,0010	1,0000	1,3881	0,1883	0,9198
0,100	0,9	3	2443	275	0,0009	1,0000	1,5259	0,1910	0,9180
0,500	0,5	1	2861	–	1,1109	0,5446	1,6303	0,1927	0,3900
0,500	0,7	0	–	–	0,1411	0,9501	0,5522	0,1961	0,9196
0,500	0,9	0	–	–	1,8385	0,2618	1,8381	1,8337	0,0593

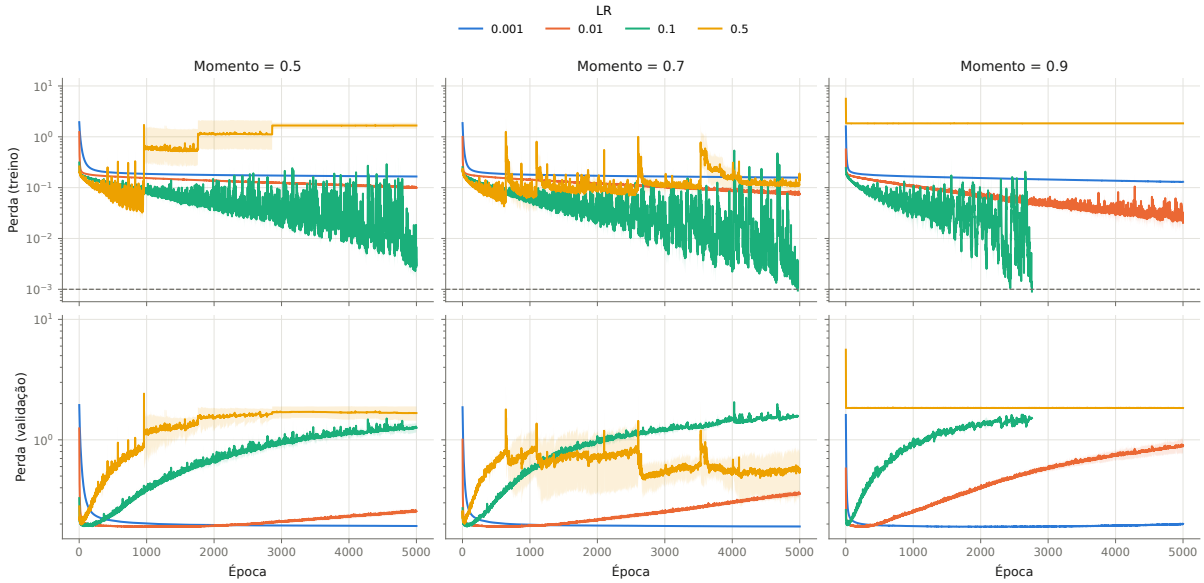


Figura 9: Curvas da grade com limite de 5.000 épocas. Uma curva que termina antes da época 5.000 atingiu o critério de 0,001 (linha tracejada).

c. Análise e discussão

Critério de 0,001. Em 500 épocas, nenhuma combinação atingiu esse valor, e por isso a velocidade da grade principal foi comparada pelo limiar de 0,20. Com limite de 5.000 épocas (Tabela 6), o critério passa a ser atingido em três combinações:

- LR = 0,1 com momento 0,9, nas três seeds, em 2.443 ± 275 épocas (de 2.273 a 2.760), a convergência mais rápida;
- LR = 0,1 com momento 0,7, nas três seeds, em 4.136 ± 730 épocas (de 3.620 a 4.972);
- LR = 0,5 com momento 0,5, em apenas uma seed, na época 2.861. As outras duas sofrem saltos abruptos da perda a partir das épocas 400 a 600 e terminam com perda de treino de 1,83 e 1,51, ou seja, colapsam.

Com LR = 0,1 e momento 0,5 a perda fica perto do critério na época 5.000 (de 0,0016 a 0,0036), com LR $\leq$ 0,01 fica longe (de 0,020 a 0,166) e com LR = 0,5 e momento 0,7 oscila em torno de 0,14. Com LR = 0,1, subir o momento de 0,7 para 0,9 reduz em 41% as épocas até o critério, o que confirma o papel do momento como acelerador.

Atingir o critério tem um custo claro: nas seis execuções com LR = 0,1 que chegaram a 0,001, a acurácia de treino é de praticamente 1,0000, enquanto a perda de validação termina entre 1,27 e 1,57. A menor perda de validação dessas mesmas execuções (cerca de 0,19) acontece entre as épocas 14 e 111, milhares de épocas antes do critério. A Medida-F de validação, que é de 0,935 com LR = 0,001, cai para 0,918 a 0,920 nas combinações com LR = 0,1 que atingem 0,001. Nesta base, em que as classes se sobrepõem, a perda de 0,001 só é alcançada quando a rede memoriza o treino.

Taxa de aprendizado muito baixa. Com LR = 0,001 e momento 0,5, são 447 épocas até a perda de 0,20, e a perda de validação ainda está caindo no fim do treino.

Taxa de aprendizado alta. Com LR $\geq$ 0,1, a perda de treino cai mais e fica ruidosa, mas a de validação sobe: LR = 0,1 com momento 0,9 termina em 0,0735 no treino e 0,5709 na validação.

As menores perdas de validação ao longo do treino são parecidas em quase toda a grade (de 0,188 a 0,196, à exceção do colapso descrito abaixo e de LR = 0,001 com momentos 0,5 e 0,7), mas são atingidas cedo quando a LR é alta. Nesse caso o problema é overfitting rápido, e a capacidade de aprender é a mesma.

Colapso. Com LR = 0,5 e momento 0,9, a perda fica em 1,84 nas três seeds e a Medida-F é 0,0593. A entropia das classes é 1,8338, e prever sempre a classe majoritária dá Medida-F de 0,0593, ou seja, a rede aprendeu apenas a proporção das classes. Como os pesos continuam finitos, nenhuma execução foi contada como divergência numérica. A causa provável é a morte de neurônios ReLU após os primeiros passos grandes, que o experimento não verificou diretamente.

Efeito do momento. O número de épocas até a perda de 0,20 acompanha a taxa efetiva $\eta/(1-m)$. O produto das épocas por essa taxa fica entre 0,89 e 0,93 nas cinco combinações com taxa efetiva de até 0,033. Assim, LR = 0,001 com momento 0,9 (taxa efetiva 0,01) leva 91 épocas, e LR = 0,01 com momento 0,5 (taxa efetiva 0,02) leva 45. Nessa faixa, o momento acelera o treino quase como aumentar a LR. A estabilidade, por outro lado, piora com os dois: o maior desvio da perda entre seeds ocorre em LR = 0,1 com momento 0,9 (0,0265).

d. Conclusão da etapa

LR = 0,01 com momento = 0,7 teve a menor perda final de validação da grade e, entre as candidatas, a convergência mais rápida, sem oscilação visível. Essa combinação fica fixa na Questão 3. Momento e taxa de aprendizado aceleram o treino de forma parecida; acima de uma taxa efetiva de aproximadamente 0,1, o ganho de velocidade vem acompanhado de overfitting rápido e, no extremo, de colapso.

Quanto ao critério do enunciado, a convergência mais rápida até a perda de 0,001 é a de LR = 0,1 com momento 0,9 (cerca de 2.400 épocas), seguida de LR = 0,1 com momento 0,7 (cerca de 4.100). Essas combinações não foram escolhidas porque, quando atingem o critério, a perda de validação já é de sete a oito vezes maior que a mínima.

4 Questão 3: número de camadas e de neurônios

a. Descrição da configuração experimental

Foram testadas 30 topologias: 1, 2 e 3 camadas ocultas iguais, de 10 a 100 neurônios por camada, em passos de 10, com três seeds cada. Ficam fixos ReLU, softmax, entropia cruzada, SGD com LR = 0,01 e momento = 0,7, e $\alpha = 10^{-4}$. A parada é perda de treino $\leq 0{,}001$ ou 500 épocas. O teste não é usado. O tempo total da tabela é o tempo por época multiplicado pelas épocas executadas.

b. Resultados

Tabela 7: As 30 topologias (média de três seeds, em 500 épocas). "Diferença" é a perda de validação menos a de treino.

Topologia	Perda treino	Perda val.	Diferença	Acurácia val.	F1 val.	dp F1	Época val. mín.	ms/época	Tempo total (s)
10	0,1835	0,2088	0,0253	0,9229	0,9322	0,0008	489	15,8	7,9
20	0,1791	0,2003	0,0212	0,9268	0,9357	0,0035	477	16,0	8,0
30	0,1756	0,1966	0,0210	0,9252	0,9350	0,0027	494	17,0	8,5
40	0,1739	0,1972	0,0233	0,9260	0,9357	0,0010	500	18,2	9,1
50	0,1743	0,1956	0,0213	0,9268	0,9363	0,0004	498	18,7	9,3
60	0,1728	0,1929	0,0201	0,9265	0,9362	0,0006	498	20,2	10,1
70	0,1727	0,1941	0,0213	0,9278	0,9371	0,0010	498	21,1	10,6
80	0,1720	0,1925	0,0205	0,9262	0,9358	0,0016	498	21,9	10,9
90	0,1717	0,1946	0,0228	0,9270	0,9371	0,0017	490	22,6	11,3
100	0,1711	0,1952	0,0241	0,9254	0,9353	0,0006	486	22,7	11,4
10×10	0,1761	0,2047	0,0286	0,9239	0,9339	0,0021	474	17,2	8,6
20×20	0,1676	0,1963	0,0287	0,9254	0,9353	0,0005	493	19,1	9,6
30×30	0,1618	0,1913	0,0295	0,9245	0,9356	0,0028	476	21,1	10,6
40×40	0,1599	0,1925	0,0326	0,9249	0,9359	0,0017	488	23,9	12,0
50×50	0,1584	0,1908	0,0323	0,9236	0,9348	0,0015	468	26,6	13,3
60×60	0,1556	0,1858	0,0301	0,9262	0,9374	0,0038	485	28,7	14,3
70×70	0,1557	0,1892	0,0335	0,9250	0,9364	0,0034	456	32,1	16,0
80×80	0,1539	0,1882	0,0342	0,9265	0,9380	0,0006	498	34,2	17,1
90×90	0,1535	0,1853	0,0318	0,9260	0,9373	0,0008	489	38,8	19,4
100×100	0,1529	0,1867	0,0338	0,9265	0,9378	0,0024	475	41,0	20,5
10×10×10	0,1735	0,2021	0,0287	0,9234	0,9339	0,0019	408	18,2	9,1
20×20×20	0,1575	0,1940	0,0365	0,9244	0,9363	0,0021	409	21,3	10,6
30×30×30	0,1558	0,2012	0,0454	0,9222	0,9338	0,0036	273	25,0	12,5
40×40×40	0,1496	0,1942	0,0446	0,9257	0,9384	0,0028	296	27,9	14,0
50×50×50	0,1479	0,1960	0,0481	0,9222	0,9347	0,0035	338	33,3	16,6
60×60×60	0,1435	0,1958	0,0523	0,9245	0,9363	0,0002	304	36,9	18,5
70×70×70	0,1403	0,1948	0,0545	0,9249	0,9364	0,0009	308	42,5	21,2
80×80×80	0,1436	0,1981	0,0545	0,9252	0,9376	0,0013	269	45,8	22,9
90×90×90	0,1378	0,1960	0,0582	0,9237	0,9362	0,0015	345	51,9	25,9
100×100×100	0,1359	0,1966	0,0607	0,9245	0,9363	0,0011	320	57,8	28,9

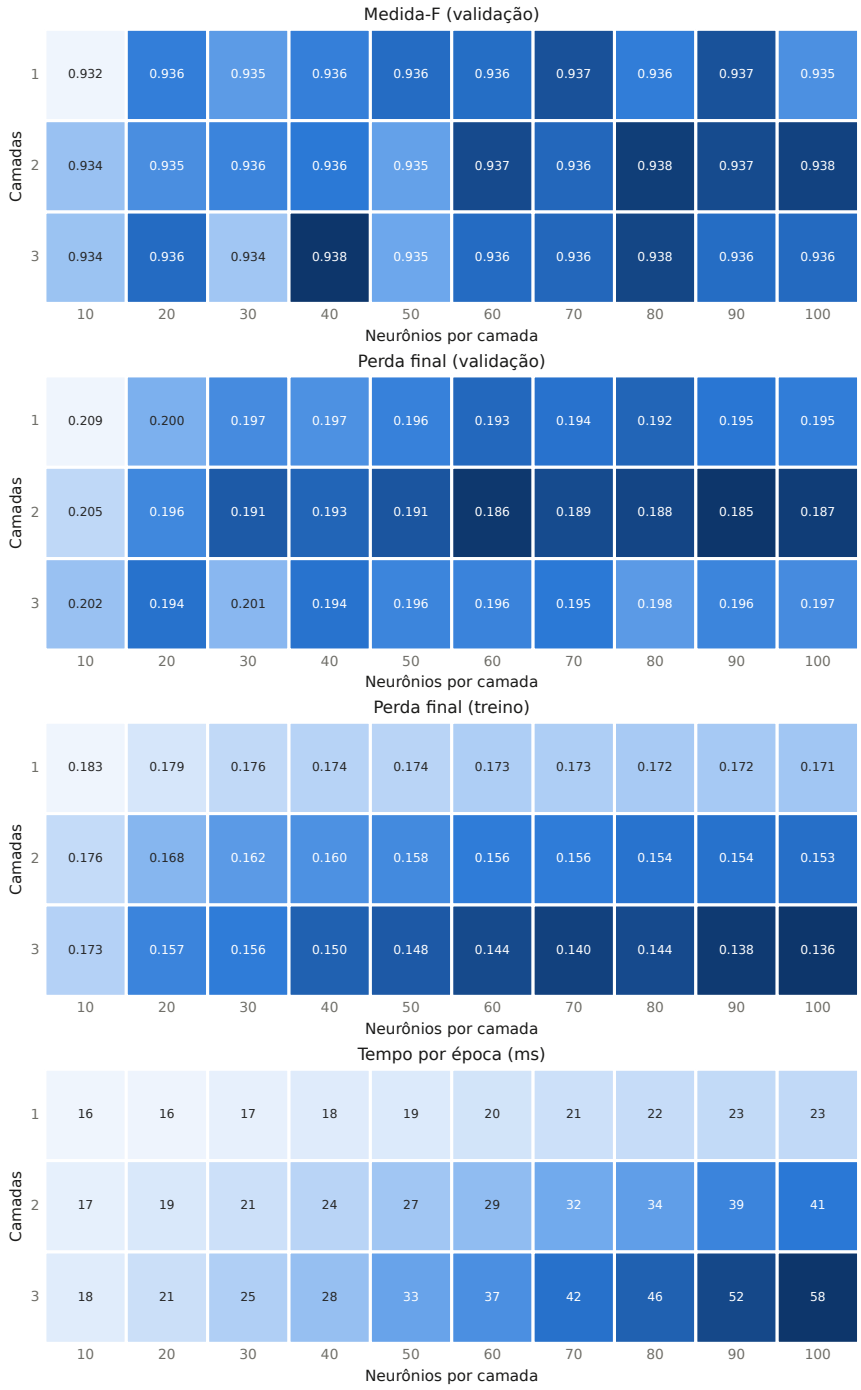


Figura 10: Medida-F, perdas e tempo por época para cada topologia.

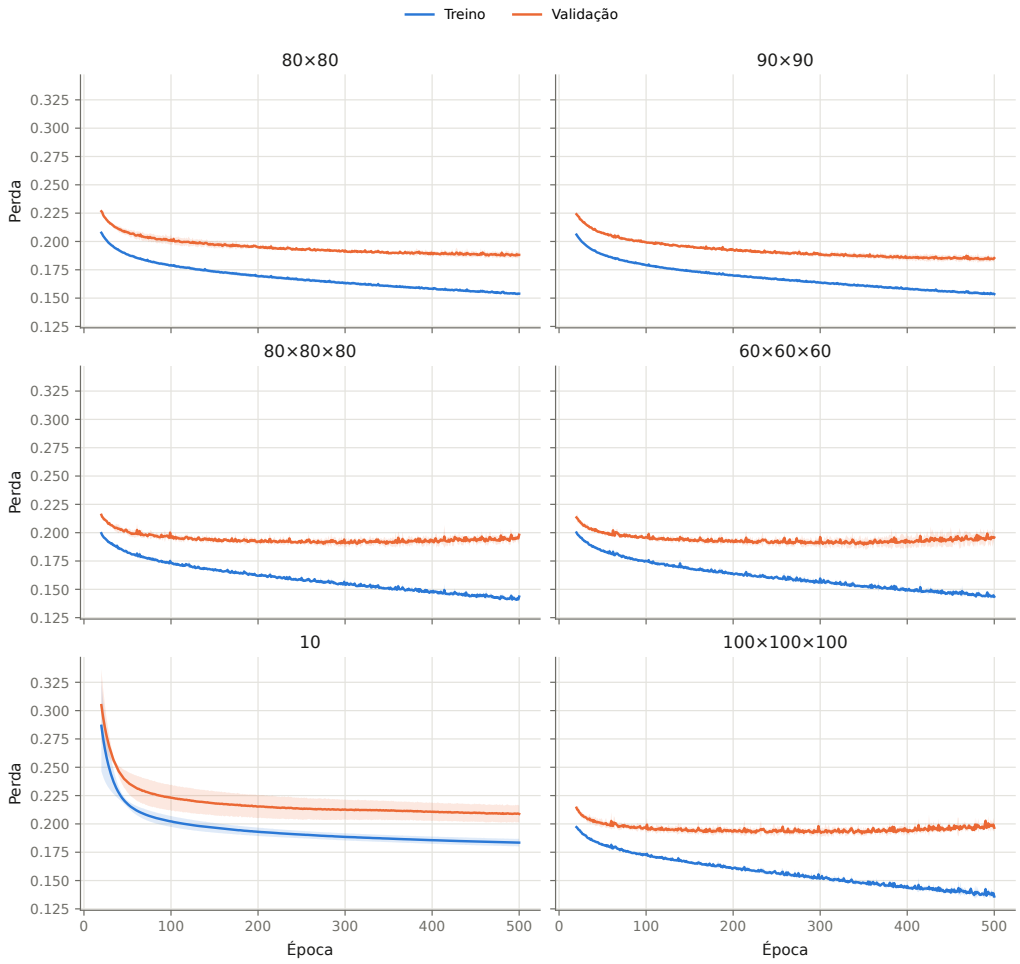


Figura 11: Perda de treino e de validação das quatro melhores redes e de dois extremos (10 e 100×100×100), a partir da época 20.

Com LR = 0,01, nenhuma topologia atinge a perda de 0,001. Para examinar esse critério, um caso de contraste à parte da grade usa a maior rede com LR = 0,1 e momento = 0,9 (Tabela 8 e Figura 12).

Tabela 8: Contraste: 100×100×100 com LR = 0,1 e momento = 0,9. Fora da grade e da seleção.

Seed	Épocas	Atingiu 0,001	Perda treino	Acur. treino	Perda val.	Acur. val.	F1 val.	Perda val. mín.	Época val. mín.
0	363	Sim	0,0009	0,9999	0,7966	0,9134	0,9278	0,1937	24
1	394	Sim	0,0008	0,9999	0,8289	0,9124	0,9265	0,1940	32
2	389	Sim	0,0009	1,0000	0,8243	0,9129	0,9243	0,1953	25

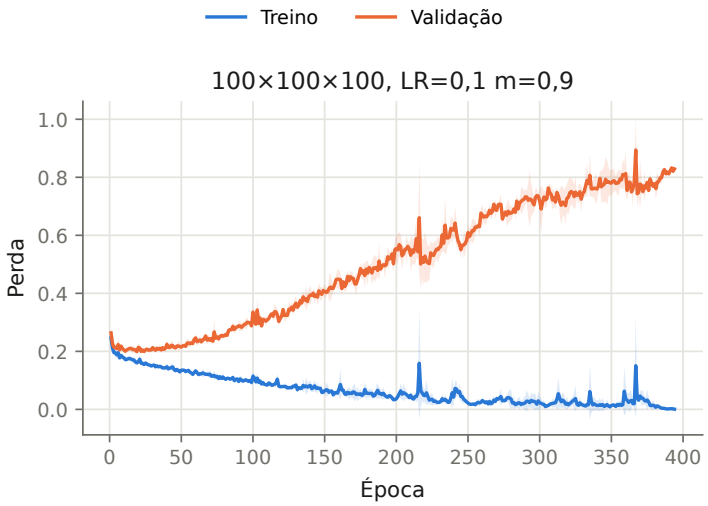


Figura 12: Perda de treino e de validação no caso de contraste.

c. Análise e discussão

A topologia muda pouco o desempenho. A Medida-F de validação vai de 0,9322 (10 neurônios) a 0,9384 (40×40×40), uma faixa de 0,0062, da mesma ordem dos desvios entre seeds (até 0,0038). Uma rede com uma camada de 70 neurônios (0,9371) fica muito perto de 80×80 (0,9380) e leva 21,1 ms por época, contra 34,2 ms.

A complexidade reduz a perda de treino, mas não a de validação. De 10 neurônios a 100×100×100, a perda de treino cai de 0,1835 para 0,1359. A de validação melhora só até redes médias e fica em torno de 0,19. A diferença entre as duas é de 0,02 com uma camada, 0,03 com duas e chega a 0,06 com três.

Underfitting. A rede de 10 neurônios tem as maiores perdas (0,1835 e 0,2088), o que é um underfitting leve, já que ela ainda alcança Medida-F de 0,9322. Nenhuma das redes testadas falha em aprender.

Overfitting. Na grade, os sinais são moderados. Com 1 e 2 camadas, a validação ainda melhora por volta da época 450 a 500. As redes com 3 camadas e pelo menos 30 neurônios atingem o mínimo entre as épocas 269 e 345 e depois sobem levemente. No contraste, o overfitting é claro: as três seeds atingem o critério de 0,001 entre as épocas 363 e 394, com acurácia de treino de pelo menos 0,9999, enquanto a perda de validação sobe de cerca de 0,19 (nas épocas 24 a 32) para mais de 0,79. A Medida-F de validação cai bem menos, para cerca de 0,926: a rede continua classificando razoavelmente, com probabilidades excessivamente confiantes. O critério de 0,001 mede, portanto, a capacidade de memorizar o treino, e atingi-lo não indica boa generalização nesta base.

Tempo. O tempo por época cresce com o número de pesos: 15,8 ms com 10 neurônios, 41,0 ms com 100×100 e 57,8 ms com 100×100×100. Em 500 épocas, o total vai de 7,9 s a 28,9 s. O ponto de equilíbrio entre generalização e custo está nas redes de uma camada com 60 a 90 neurônios ou nas de duas camadas com 60 a 80. Os ganhos das redes maiores ficam dentro da variação entre seeds.

d. Seleção das melhores topologias

A regra, fixada antes de rodar, ordena as redes pela média menos o desvio da Medida-F de validação, o que pontua desempenho e estabilidade.

Tabela 9: As quatro topologias selecionadas.

Topologia	Perda treino	Perda val.	Diferença	Acurácia val.	F1 val.	dp F1	Precisão	Revocação	Época val. mín.	Épocas	ms/época	Tempo total (s)
80×80	0,1539	0,1882	0,0342	0,9265	0,9380	0,0006	0,9383	0,9380	498	500	34,2	17,1
90×90	0,1535	0,1853	0,0318	0,9260	0,9373	0,0008	0,9376	0,9374	489	500	38,8	19,4
80×80×80	0,1436	0,1981	0,0545	0,9252	0,9376	0,0013	0,9378	0,9382	269	500	45,8	22,9
60×60×60	0,1435	0,1958	0,0523	0,9245	0,9363	0,0002	0,9365	0,9365	304	500	36,9	18,5

- **80×80:** a melhor pontuação, com Medida-F de 0,9380 e desvio de só 0,0006.
- **90×90:** a menor perda final de validação entre as selecionadas (0,1853), com desvio de 0,0008.
- **80×80×80:** a representante com três camadas, com Medida-F de 0,9376, embora com diferença de perda maior (0,0545) e o maior custo do grupo (45,8 ms por época).
- **60×60×60:** o menor desvio da grade (0,0002), com custo menor que o da rede anterior (36,9 ms).

A rede 40×40×40 tem a maior média (0,9384), mas fica de fora pelo desvio de 0,0028. A ordem das quatro é pouco sensível em termos práticos, dada a proximidade dos valores.

e. Conclusão da etapa

Nesta base, com LR = 0,01, o número de camadas e de neurônios tem efeito pequeno na generalização. O aumento de capacidade reduz a perda de treino e aumenta o custo, e os sinais de overfitting crescem com a profundidade. As quatro redes seguem para a Questão 6, e a 80×80 é a base das Questões 4 e 5.

5 Questão 4: quantidade e qualidade dos dados de treino

a. Descrição do experimento

Rede 80×80 com LR = 0,01, momento = 0,7, ReLU, softmax e entropia cruzada, por até 500 épocas e com cinco seeds. Validação e teste permanecem fixos em todas as condições, de modo que os números são comparáveis. A seed define tanto a amostra quanto os pesos iniciais.

- **Quantidade:** 5, 10, 20, 40, 60, 80 e 100% do conjunto de treino, com amostragem estratificada. As frações de 5 e 10% foram acrescentadas às sugeridas para localizar melhor a região de queda.
- **Qualidade dos rótulos:** 5, 10 e 20% dos rótulos de treino trocados por outra classe sorteada. Validação e teste mantêm os rótulos corretos.
- **Representatividade:** amostragem estratificada contra aleatória, com 5 e 20% dos dados.

b. Resultados

Tabela 10: Efeito da quantidade de exemplos de treino (média de cinco seeds).

Condição	Perda treino	Perda val.	Perda teste	Acur. val.	Acur. teste	F1 val.	dp val.	F1 teste	dp teste	N treino	Atualizações	ms/época
5%	0,1446	0,2666	0,2848	0,9110	0,9062	0,9203	0,0038	0,9176	0,0028	473	1500	2,6
10%	0,1440	0,2447	0,2654	0,9200	0,9118	0,9283	0,0028	0,9234	0,0024	947	2500	4,2
20%	0,1490	0,2246	0,2502	0,9225	0,9166	0,9318	0,0029	0,9271	0,0030	1895	5000	7,4
40%	0,1514	0,2131	0,2343	0,9235	0,9202	0,9333	0,0027	0,9305	0,0023	3791	9500	14,0
60%	0,1509	0,2057	0,2266	0,9223	0,9232	0,9331	0,0045	0,9332	0,0022	5687	14500	21,0
80%	0,1543	0,1981	0,2173	0,9227	0,9232	0,9340	0,0012	0,9335	0,0014	7583	19000	27,9
100%	0,1540	0,1894	0,2108	0,9265	0,9256	0,9379	0,0014	0,9358	0,0010	9479	24000	35,5

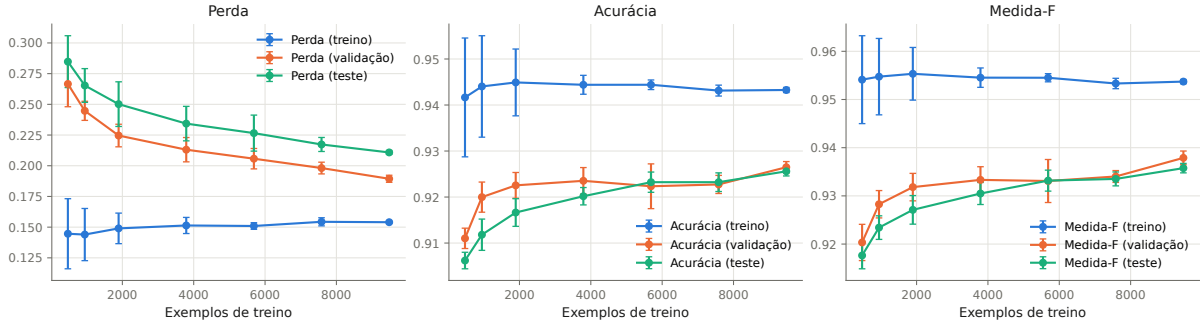


Figura 13: Curvas de generalização: perda, acurácia e Medida-F contra o número de exemplos de treino. As barras indicam ± 1 dp.

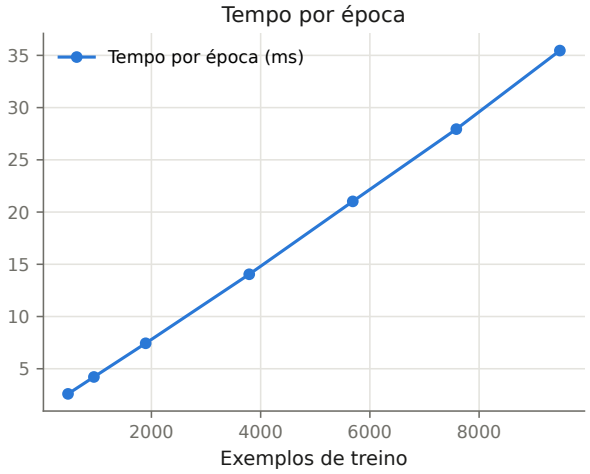


Figura 14: Tempo por época contra o número de exemplos de treino.

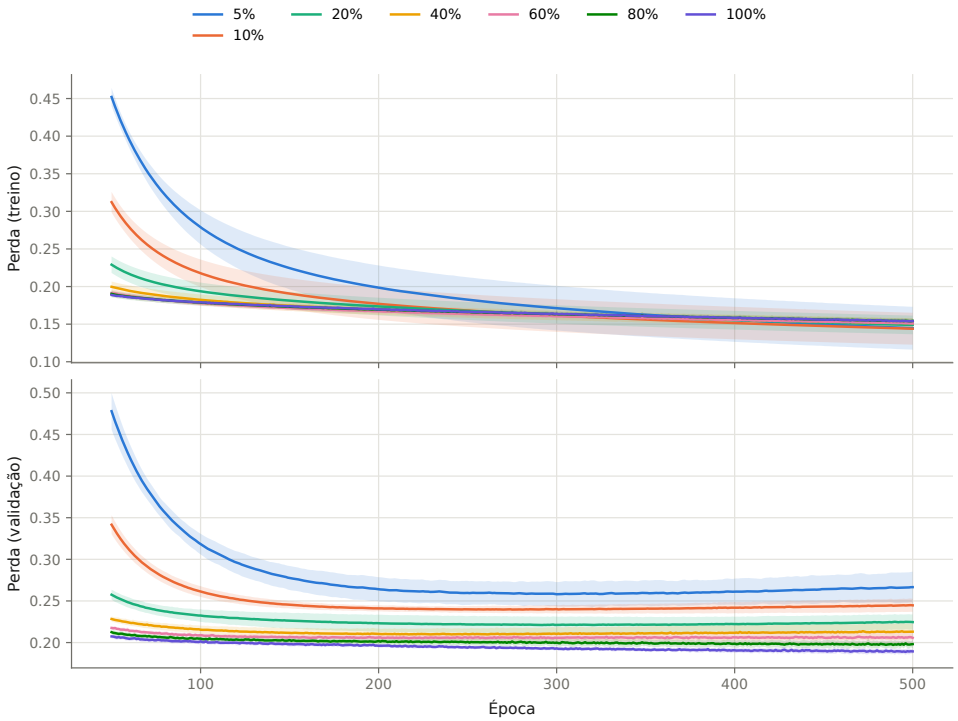


Figura 15: Curvas de perda para cada fração de dados, a partir da época 50.

Tabela 11: Efeito de rótulos errados no treino, com 100% dos dados.

Condição	Perda treino	Perda val.	Perda teste	Acur. val.	Acur. teste	F1 val.	dp val.	F1 teste	dp teste
100%	0,1540	0,1894	0,2108	0,9265	0,9256	0,9379	0,0014	0,9358	0,0010
5% de ruído	0,4031	0,2319	0,2474	0,9249	0,9234	0,9355	0,0015	0,9339	0,0023
10% de ruído	0,5966	0,2804	0,2951	0,9244	0,9215	0,9352	0,0011	0,9323	0,0018
20% de ruído	0,9156	0,3891	0,4029	0,9254	0,9207	0,9352	0,0015	0,9314	0,0023

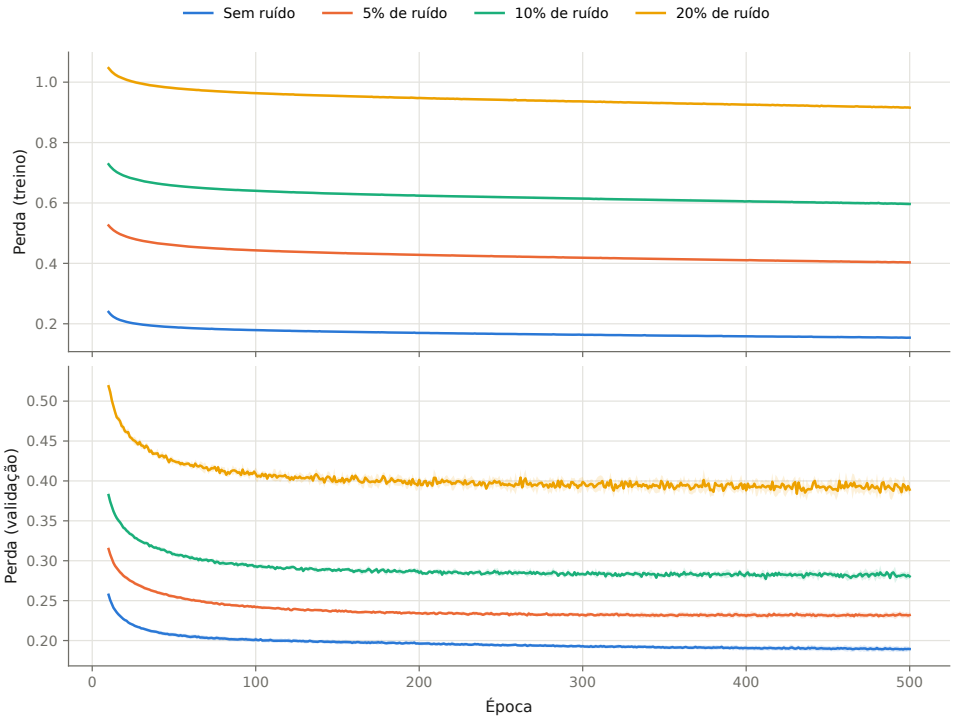


Figura 16: Curvas de perda com rótulos de treino corrompidos, a partir da época 10.

Tabela 12: Amostragem estratificada contra aleatória.

Condição	Perda treino	Perda val.	Perda teste	Acur. val.	Acur. teste	F1 val.	dp val.	F1 teste	dp teste
5% estratificada	0,1446	0,2666	0,2848	0,9110	0,9062	0,9203	0,0038	0,9176	0,0028
20% estratificada	0,1490	0,2246	0,2502	0,9225	0,9166	0,9318	0,0029	0,9271	0,0030
5% aleatória	0,1367	0,2672	0,2837	0,9125	0,9052	0,9197	0,0080	0,9155	0,0082
20% aleatória	0,1567	0,2223	0,2366	0,9221	0,9182	0,9310	0,0027	0,9296	0,0029

c. Análise e discussão

Quantidade. A generalização melhora de forma contínua, com retorno decrescente. De 5 a 40%, a Medida-F de teste vai de 0,9176 a 0,9305. De 40 a 100%, ganha só mais 0,0053 e chega a 0,9358. A perda de treino pouco muda (0,14 a 0,15), enquanto a de validação cai de 0,2666 para 0,1894: a diferença entre as duas passa de 0,122 para 0,035. A perda de validação não satura dentro da faixa testada, embora a Medida-F quase sature. Isso indica que mais dados ainda melhoram a qualidade das probabilidades previstas, mesmo com poucos erros de classe a menos.

Há uma ressalva de desenho: como o limite é de 500 épocas, frações menores recebem menos atualizações dos pesos (1.500 com 5% e 24.000 com 100%). Nas curvas, a perda de treino de todas as frações converge para o mesmo nível antes da época 500, o que sugere que a falta de atualizações não domina o resultado. O efeito, porém, não foi separado.

Qualidade dos rótulos. O ruído afeta mais a perda do que a classificação. Com 20% de rótulos errados, a perda de validação dobra (de 0,1894 para 0,3891), enquanto a Medida-F de teste cai de 0,9358 para 0,9314. Como o ruído é uniforme, a classe correta continua sendo a mais frequente em cada região do espaço de atributos, e a decisão muda pouco. O que piora é a confiança das probabilidades. Um ruído concentrado em classes parecidas, como Sira e Dermason, provavelmente causaria mais dano, mas isso não foi testado.

Representatividade. A estratificação quase não muda a média, mas reduz a variabilidade em

amostras muito pequenas: com 5% dos dados, o desvio da Medida-F de teste é de 0,0028 na estratificada e de 0,0082 na aleatória. Com 20%, os desvios são quase iguais (0,0030 e 0,0029) e os dois métodos se equivalem.

Tempo. O tempo por época é linear no número de exemplos: 2,6 ms com 473 e 35,5 ms com 9.479. Em 500 épocas, são cerca de 1,3 s e 17,8 s.

d. Conclusão da etapa

A rede já generaliza bem com poucos dados, e o ganho a partir de cerca de 40% do treino (3.791 exemplos) é pequeno em Medida-F. O custo cresce de forma linear e é baixo nesta base, portanto o melhor equilíbrio é usar todos os dados disponíveis, que dão a menor perda e o menor desvio no teste. Com um limite real de coleta, 40 a 60% já entregariam uma Medida-F de teste a cerca de 0,005 ou menos da obtida com todos os dados. A rede mostrou boa tolerância a ruído uniforme nos rótulos, com perda de qualidade concentrada nas probabilidades.

6 Questão 5: quantidade, qualidade e sensibilidade dos atributos

a. Descrição do experimento

A rede é a mesma da Questão 4 (80×80, LR = 0,01, momento = 0,7, ReLU, softmax, entropia cruzada, até 500 épocas), com três seeds por subconjunto.

Critérios. A relevância é medida pela queda da Medida-F de validação ao embaralhar o atributo (média de três redes). A redundância é $|r| > 0{,}95$ no treino: percorrendo os atributos do mais ao menos importante, cada um só entra se não for redundante com os já mantidos. O ruído é representado por colunas gaussianas artificiais.

Conjuntos testados.

- todos os 16 atributos;
- os 12, 8 e 4 mais importantes por permutação;
- 10 atributos não redundantes;
- agrupamento físico: só tamanho (6 atributos) e só forma (10 atributos);
- todos, mais 5 colunas de ruído (21);
- 8 atributos sorteados, um sorteio por seed em cinco seeds;
- remoção de um atributo por vez (16 conjuntos de 15).

A regra de escolha, fixada antes de rodar, é: entre os conjuntos nomeados (sem ruído e sem sorteio), o menor cuja Medida-F de validação fique a até um desvio da melhor. O teste é só reportado.

b. Resultados

Tabela 13: Resultados por conjunto de atributos. Com 8 atributos sorteados, os conjuntos mudam a cada seed, e por isso o tempo não foi medido.

Conjunto	N	Perda treino	Perda val.	Acur. val.	F1 val.	dp F1	F1 teste	Épocas até 0,20	ms/época
Todos	16	0,1539	0,1882	0,9265	0,9380	0,0006	0,9353	27,3	35,6
Top 12	12	0,1628	0,1925	0,9240	0,9349	0,0003	0,9328	31,0	35,0
Top 8	8	0,1730	0,1943	0,9214	0,9325	0,0017	0,9312	43,7	34,5
Top 4	4	0,1843	0,1950	0,9214	0,9318	0,0021	0,9274	112,0	33,7
Sem redundantes (10)	10	0,1554	0,1855	0,9250	0,9365	0,0004	0,9345	26,3	35,0
Só tamanho	6	0,2245	0,2499	0,9111	0,9197	0,0011	0,9210	–	32,7
Só forma	10	0,1536	0,1871	0,9267	0,9384	0,0018	0,9362	36,7	34,7
Todos + 5 de ruído	21	0,1258	0,2179	0,9209	0,9325	0,0014	0,9288	30,0	36,7
8 aleatórios	8	0,2001	0,2258	0,9138	0,9223	0,0117	0,9243	238,2	–

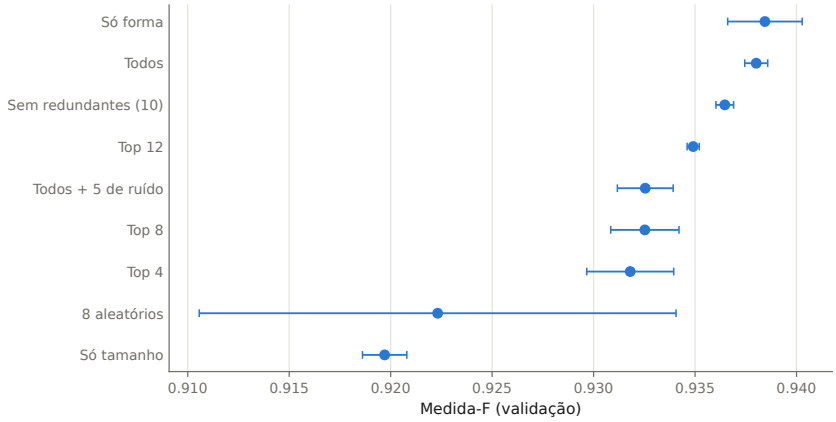


Figura 17: Medida-F de validação por conjunto, com ± 1 dp.

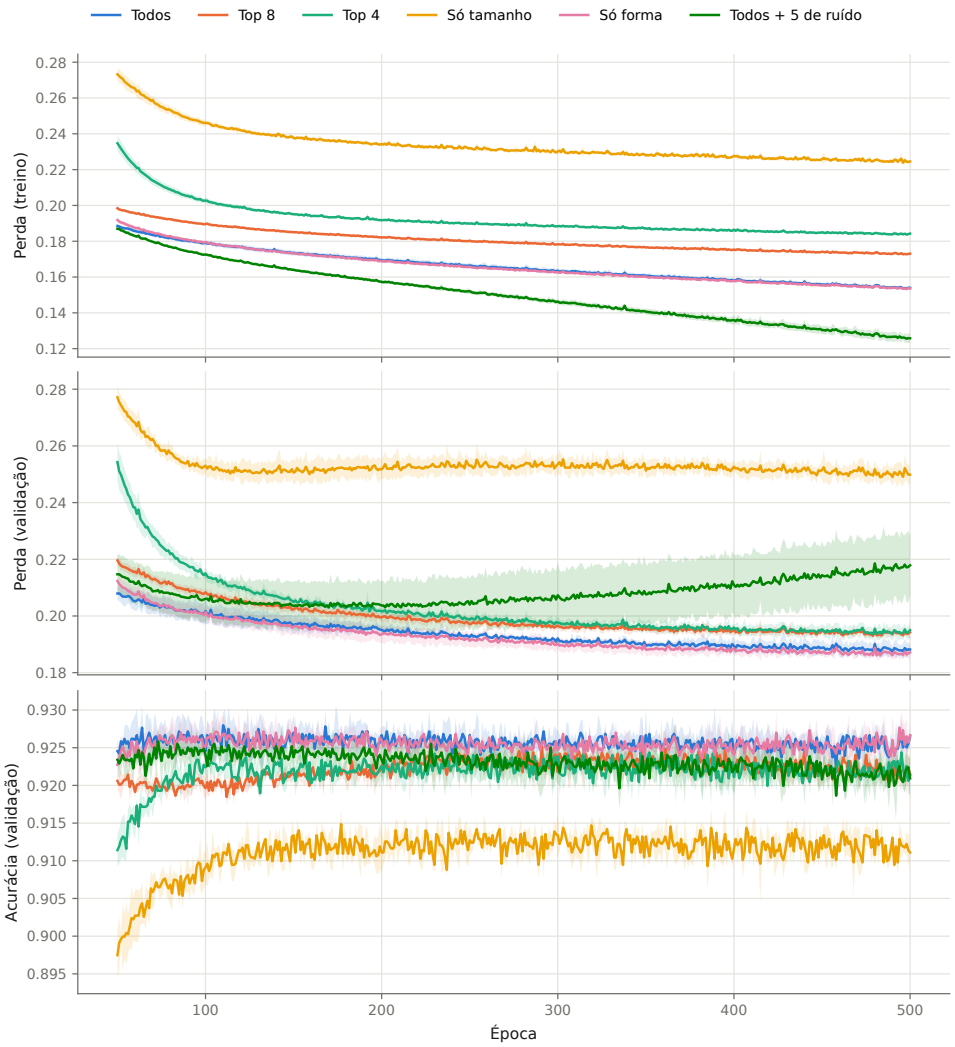


Figura 18: Curvas de perda e de acurácia para seis conjuntos, a partir da época 50.

Tabela 14: Importância por permutação na validação.

Atributo	Queda de F1	dp
roundness	0,1139	0,0032
ConvexArea	0,1028	0,0347
ShapeFactor4	0,1022	0,0030
ShapeFactor1	0,0915	0,0251
ShapeFactor2	0,0746	0,0339
Area	0,0712	0,0166
Eccentricity	0,0526	0,0046
Compactness	0,0344	0,0091
MinorAxisLength	0,0338	0,0054
EquivDiameter	0,0255	0,0106
Solidity	0,0231	0,0003
AspectRation	0,0226	0,0050
ShapeFactor3	0,0206	0,0121
Perimeter	0,0185	0,0029
MajorAxisLength	0,0173	0,0099
Extent	0,0058	0,0011

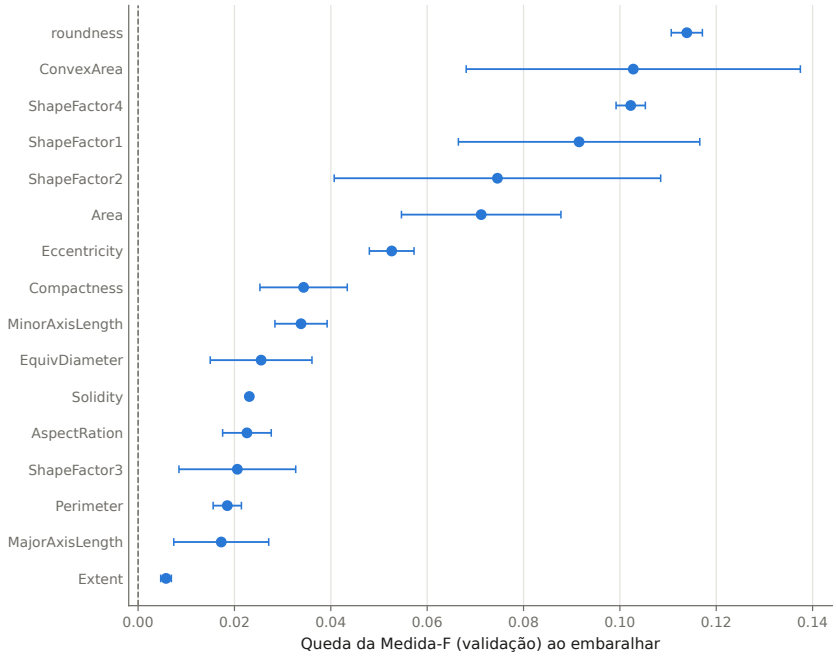


Figura 19: Queda da Medida-F ao embaralhar cada atributo.

Tabela 15: Remoção de um atributo por vez, em relação aos 16 atributos (Medida-F de validação de 0,9380).

Remoção	F1 val.	dp	Variação	F1 teste
Sem ShapeFactor4	0,9305	0,0011	-0,0075	0,9274
Sem Extent	0,9343	0,0012	-0,0037	0,9329
Sem Solidity	0,9354	0,0010	-0,0026	0,9340
Sem ShapeFactor3	0,9364	0,0026	-0,0016	0,9346
Sem Perimeter	0,9373	0,0007	-0,0008	0,9363
Sem Eccentricity	0,9376	0,0009	-0,0004	0,9363
Sem ShapeFactor1	0,9376	0,0010	-0,0004	0,9338
Sem roundness	0,9379	0,0017	-0,0001	0,9350
Sem AspectRation	0,9380	0,0005	0,0000	0,9349
Sem MinorAxisLength	0,9381	0,0011	0,0001	0,9349
Sem Area	0,9381	0,0010	0,0001	0,9353
Sem ShapeFactor2	0,9382	0,0023	0,0002	0,9346
Sem MajorAxisLength	0,9385	0,0011	0,0005	0,9339
Sem Compactness	0,9386	0,0015	0,0006	0,9359
Sem EquivDiameter	0,9393	0,0014	0,0013	0,9338
Sem ConvexArea	0,9394	0,0018	0,0014	0,9347

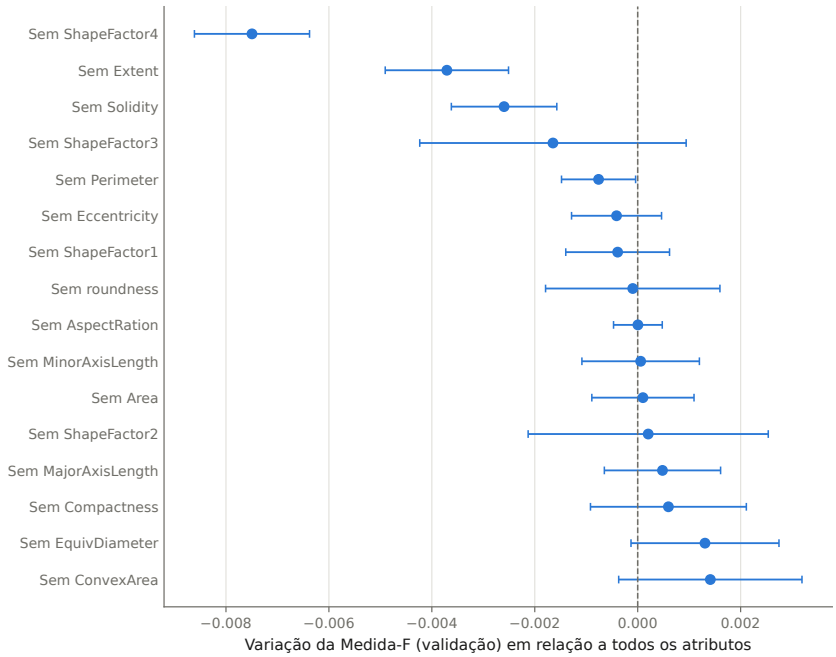


Figura 20: Variação da Medida-F ao remover cada atributo. As barras mostram o dp do conjunto com a remoção.

c. Análise e discussão

Remoção e inclusão. Reduzir de 16 para 10 atributos não custa nada mensurável, se a escolha for boa: "Só forma" tem Medida-F de 0,9384 e "Sem redundantes", 0,9365, contra 0,9380 de todos. Cortar mais custa pouco: 0,9318 com 4 atributos, mas a convergência fica mais lenta (112 épocas até a perda de 0,20, contra 27). Conjuntos escolhidos sem critério são piores: os 8 sorteados têm média de 0,9223 e desvio de 0,0117, o que mostra que a qualidade pesa mais que a

quantidade de atributos.

Tamanho e forma. Os 6 atributos de tamanho sozinhos caem para 0,9197, o pior resultado, e nunca chegam à perda de treino de 0,20. Os de forma igualam o conjunto completo, dentro da variação entre seeds. Isso se explica em parte pela definição dos atributos: `ShapeFactor1` e `ShapeFactor2` são comprimentos de eixo divididos pela área [1], e por isso o conjunto de forma também carrega informação de escala.

Atributos redundantes. Os atributos de tamanho são quase cópias uns dos outros. Removê-los um a um praticamente não altera a Medida-F, e as variações ficam em torno de um desvio.

Atributos ruidosos. As 5 colunas de ruído reduzem a perda de treino (de 0,1539 para 0,1258), mas aumentam a de validação (de 0,1882 para 0,2179) e reduzem a Medida-F de 0,9380 para 0,9325. A rede usa a capacidade extra para memorizar ruído, e a curva de validação passa a subir depois de cerca de 150 épocas. Esse é um caso de overfitting provocado apenas pela entrada.

Permutação contra remoção. Os dois métodos discordam, e a discordância é informativa. `ConvexArea` perde 0,1028 quando embaralhado, mas sua remoção não piora o resultado (variação de +0,0014). O motivo é a correlação: embaralhar um atributo quase igual a `Area` cria combinações que nunca existiram no treino, e a rede erra; removê-lo não muda a informação disponível. Logo, a permutação mede a dependência do modelo treinado, e a remoção mede se a informação é insubstituível. Por esse segundo critério, os atributos mais relevantes são `ShapeFactor4` (−0,0075), `Extent` (−0,0037) e `Solidity` (−0,0026). `ShapeFactor4` é o único que se destaca nos dois métodos. Como cada remoção usa só três seeds, as variações menores que cerca de 0,001 devem ser lidas como empate.

Dimensionalidade e tempo. O tempo por época varia pouco: 32,7 ms com 6 atributos e 36,7 ms com 21, porque os pesos de entrada são uma pequena parte do total nesta rede. A dimensionalidade não afetou a estabilidade dos conjuntos bem escolhidos. A estabilidade dependeu de quais atributos entram.

d. Conclusão da etapa

O conjunto com melhor equilíbrio é **"Só forma"** (10 atributos: `AspectRation`, `Eccentricity`, `Extent`, `Solidity`, `roundness`, `Compactness` e os quatro `ShapeFactor`). Ele teve a maior Medida-F de validação entre os conjuntos nomeados e empata com os 16 atributos usando 6 a menos, com tempo por época praticamente igual. O conjunto "Sem redundantes" ficou 0,0001 abaixo do corte da regra e é uma alternativa equivalente. O ganho principal é a simplicidade da entrada, já que a economia de tempo é pequena.

7 Questão 6: validação inicial no conjunto de teste

a. Descrição do experimento

Redes. As quatro topologias da Questão 3 (80×80, 90×90, 80×80×80 e 60×60×60), com ReLU, softmax, entropia cruzada, SGD com LR = 0,01 e momento = 0,7, usando os 10 atributos de forma da Questão 5. O critério de seleção vem da Questão 3: média menos desvio da Medida-F de validação.

Ajustes, decididos na validação. Testou-se α em $\{10^{-4}, 10^{-3}, 10^{-2}\}$ para cada topologia (três seeds), e ficou o valor de menor perda mínima de validação. O limite de épocas passou a ser a época média dessa perda mínima, para interromper o treino antes de o overfitting avançar (Tabela 16).

Avaliação. Cada rede ajustada foi treinada com cinco seeds no conjunto de treino. O conjunto de teste entra para comparar a generalização, com a perda de entropia cruzada, a acurácia e a Medida-F.

b. Resultados

Tabela 16: Ajuste de regularização nos atributos de forma, na validação (três seeds).

Topologia	alpha	Perda treino	Perda val.	Perda val. mín.	Época val. mín.	F1 val.
80×80	0,0001	0,1536	0,1871	0,1857	481	0,9384
80×80	0,0010	0,1537	0,1872	0,1857	481	0,9383
80×80	0,0100	0,1545	0,1875	0,1860	486	0,9382
90×90	0,0001	0,1552	0,1892	0,1874	468	0,9378
90×90	0,0010	0,1553	0,1893	0,1875	468	0,9382
90×90	0,0100	0,1560	0,1888	0,1870	480	0,9379
80×80×80	0,0001	0,1422	0,1930	0,1853	332	0,9379
80×80×80	0,0010	0,1424	0,1934	0,1851	324	0,9376
80×80×80	0,0100	0,1434	0,1916	0,1847	342	0,9385
60×60×60	0,0001	0,1417	0,1976	0,1900	269	0,9375
60×60×60	0,0010	0,1420	0,1974	0,1900	280	0,9374
60×60×60	0,0100	0,1432	0,1961	0,1902	309	0,9369

Tabela 17: As quatro redes ajustadas, em treino e teste (média de cinco seeds). A coluna dp refere-se à Medida-F de teste.

Topologia	alpha	Épocas	Perda treino	Perda teste	Acur. treino	Acur. teste	F1 treino	F1 teste	dp F1
80×80	0,0001	481	0,1542	0,2139	0,9434	0,9249	0,9540	0,9359	0,0011
90×90	0,0100	480	0,1560	0,2114	0,9423	0,9254	0,9530	0,9361	0,0022
80×80×80	0,0100	342	0,1506	0,2184	0,9447	0,9238	0,9549	0,9345	0,0010
60×60×60	0,0001	269	0,1570	0,2137	0,9425	0,9242	0,9527	0,9353	0,0020

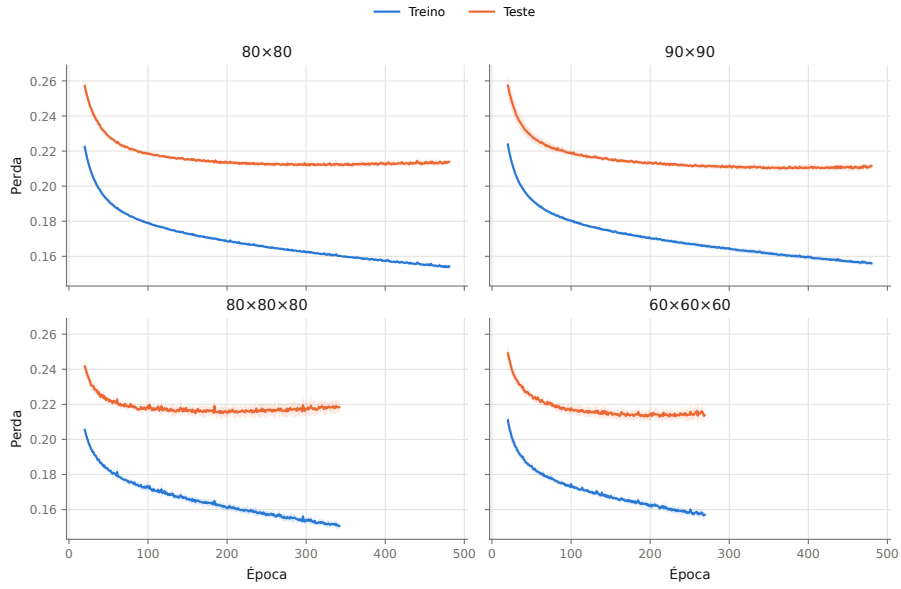


Figura 21: Perda de treino e de teste das quatro redes, a partir da época 20.

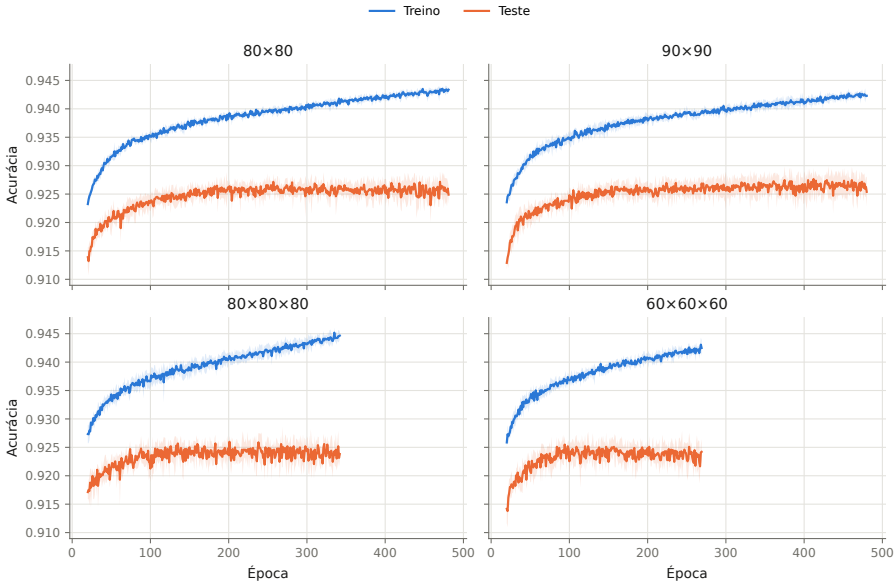


Figura 22: Acurácia de treino e de teste das quatro redes, a partir da época 20.

Tabela 18: Rede vencedora no teste, por classe (seed de Medida-F mediana).

Classe	Precisão	Revocação	Medida-F	Exemplos
BARBUNYA	0,9235	0,9141	0,9188	198
BOMBAY	1,0000	1,0000	1,0000	78
CALI	0,9216	0,9592	0,9400	245
DERMASON	0,9324	0,9079	0,9200	532
HOROZ	0,9701	0,9319	0,9506	279
SEKER	0,9535	0,9441	0,9488	304
SIRA	0,8486	0,8914	0,8695	396
macro avg	0,9357	0,9355	0,9354	2032

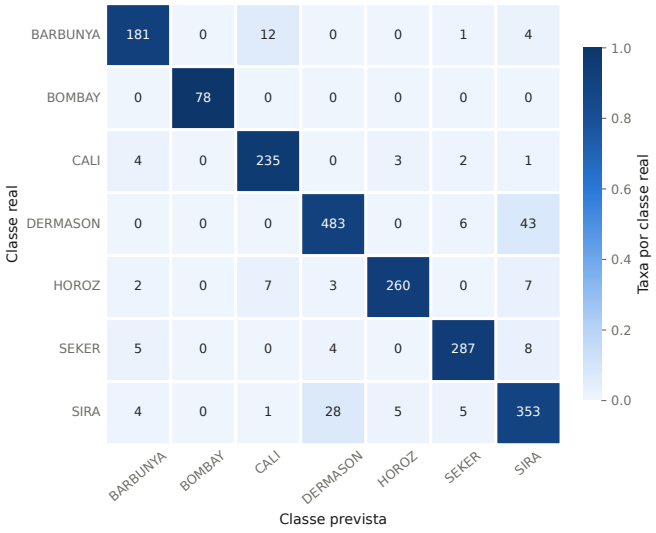


Figura 23: Matriz de confusão da rede vencedora no teste. A cor é a taxa por classe real, e o número é a contagem.

Pela regra de maior média menos desvio, a melhor rede é **80×80** ($\alpha = 10^{-4}$, 481 épocas), com pontuação de 0,9348. Ela tem Medida-F de teste de 0,9359, com o segundo menor desvio (0,0011).

c. Análise e discussão

As quatro redes são equivalentes na prática. As Medidas-F de teste ficam entre 0,9345 e 0,9361, uma diferença máxima de 0,0016, menor que o desvio entre seeds de duas delas. A rede 90×90 tem a maior média (0,9361), mas com o dobro do desvio de 80×80. A escolha segue a regra, e os dados não sustentam a afirmação de que uma delas é superior. A 80×80 também tem tempo por época menor que o da 90×90 e o da 80×80×80 (Questão 3).

Treino e teste. A rede vencedora tem Medida-F de 0,9540 no treino e 0,9359 no teste, e perda de 0,1542 e 0,2139. Essa diferença existe em todas as redes e se mantém estável ao longo das épocas, sem aumento expressivo da perda de teste. Há um overfitting leve e nenhum sinal de underfitting. O teste também parece mais difícil que a validação para esta divisão específica: a perda é de 0,2139 no teste e cerca de 0,187 na validação, e a Questão 7 ajuda a avaliar essa diferença.

Ajustes. A regularização quase não teve efeito: dentro de cada topologia, a perda mínima de validação varia no máximo 0,0006 entre os valores de α. Valores maiores de α foram escolhidos em duas redes, mas com diferenças que não têm peso prático. A interrupção do treino importa um pouco mais nas redes de 3 camadas, em que o mínimo surge antes (269 e 342 épocas). O maior ajuste foi usar os atributos de forma, que mantêm o desempenho com uma entrada menor.

Erros por classe. Bombay é classificada sem erros, com 78 de 78 exemplos. Sira tem a menor Medida-F (0,8695), e a maior parte dos erros está entre Sira e Dermason: 43 exemplos de Dermason previstos como Sira, e 28 no sentido oposto. A confusão seguinte é de 12 exemplos de Barbunya previstos como Cali. O erro restante se deve, portanto, à sobreposição entre variedades parecidas, o que mais capacidade de rede não parece resolver.

d. Conclusão da etapa

A configuração final é a rede **80×80** com ReLU, softmax, entropia cruzada, SGD com LR = 0,01, momento = 0,7, $\alpha = 10^{-4}$, 481 épocas e 10 atributos de forma. Ela combina Medida-F de teste entre as mais altas e desvio pequeno, com tempo por época menor que o da 90×90, a rede de maior média. Como as finalistas são muito próximas em uma única divisão dos dados, a validação cruzada da próxima etapa é necessária para estimar a generalização sem depender dessa divisão.

8 Questão 7: validação cruzada k-fold

a. Descrição do experimento

Valor de k. Foi usado k = 10. Cada teste tem cerca de 1.354 exemplos, dos quais cerca de 52 são da menor classe (Bombay), o que ainda dá uma estimativa razoável por classe. Cada treino usa 90% dos dados, perto do que o modelo final usaria. O custo é baixo para esta base.

Configuração. Rede 80×80, ReLU, softmax, entropia cruzada, SGD com LR = 0,01 e momento = 0,7, $\alpha = 10^{-4}$, 481 épocas, 10 atributos de forma.

Procedimento. A divisão usa `StratifiedKFold` sobre a base completa sem duplicatas (13.543 exemplos), o que mantém a proporção das classes em cada partição. Em cada rodada, o z-score

é ajustado só nas nove partições de treino. A seed dos pesos é a mesma em todas as rodadas, de modo que a variação observada vem das partições. A regressão logística, nas mesmas partições, serve de referência linear.

b. Resultados

Tabela 19: Métricas de teste por partição e perda de treino final.

Partição	Perda	Acurácia	Medida-F	Precisão	Revocação	Perda treino
fold 1	0,2417	0,9151	0,9291	0,9312	0,9275	0,1561
fold 2	0,2039	0,9299	0,9437	0,9459	0,9420	0,1575
fold 3	0,1740	0,9402	0,9500	0,9504	0,9497	0,1613
fold 4	0,1895	0,9291	0,9385	0,9422	0,9352	0,1594
fold 5	0,1893	0,9247	0,9348	0,9348	0,9351	0,1599
fold 6	0,1447	0,9476	0,9572	0,9576	0,9568	0,1630
fold 7	0,1680	0,9417	0,9496	0,9517	0,9476	0,1610
fold 8	0,1652	0,9431	0,9512	0,9517	0,9508	0,1612
fold 9	0,1883	0,9254	0,9392	0,9409	0,9379	0,1604
fold 10	0,1805	0,9321	0,9422	0,9417	0,9430	0,1604

Tabela 20: Média, variância e extremos das métricas entre as dez partições.

Métrica	Média	Variância	Desvio	Mínimo	Máximo
Perda	0,18452	0,00067	0,02597	0,14468	0,24172
Acurácia	0,93288	0,00010	0,01008	0,91513	0,94756
Medida-F	0,94355	0,00007	0,00853	0,92908	0,95716
Precisão	0,94482	0,00007	0,00823	0,93120	0,95763
Revocação	0,94258	0,00008	0,00886	0,92752	0,95683

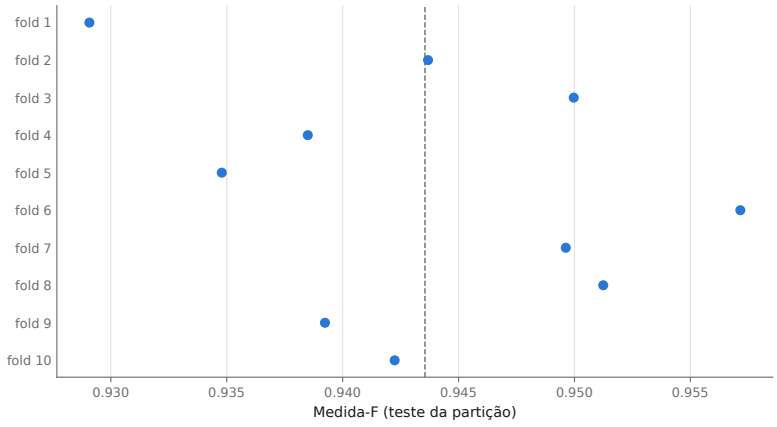


Figura 24: Medida-F de teste por partição. A linha tracejada marca a média.

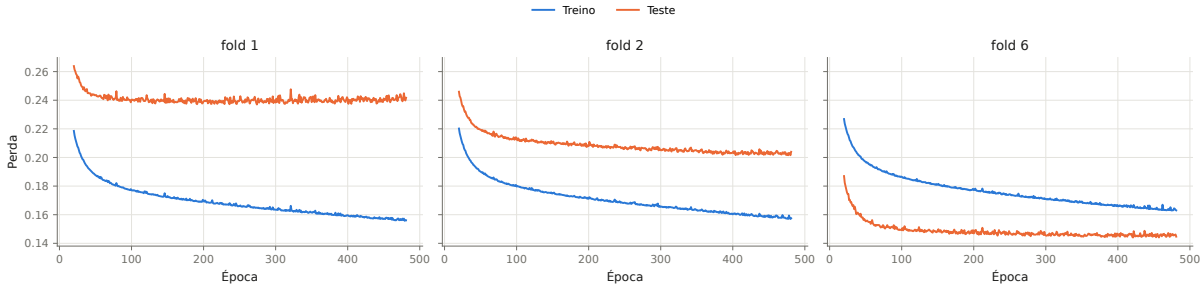


Figura 25: Perda de treino e de teste na pior (1), na mediana (2) e na melhor (6) partição, a partir da época 20.

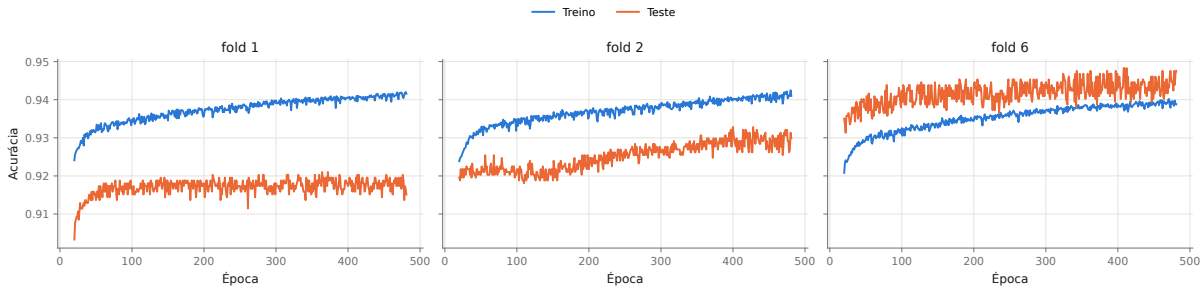


Figura 26: Acurácia de treino e de teste nas mesmas partições, a partir da época 20.

Tabela 21: Métricas por classe, com as previsões das dez partições reunidas.

Classe	Precisão	Revocação	Medida-F	Exemplos
BARBUNYA	0,9433	0,9312	0,9372	1322
BOMBAY	0,9981	1,0000	0,9990	522
CALI	0,9421	0,9485	0,9453	1630
DERMASON	0,9169	0,9363	0,9265	3546
HOROZ	0,9645	0,9500	0,9572	1860
SEKER	0,9594	0,9551	0,9572	2027
SIRA	0,8882	0,8771	0,8826	2636

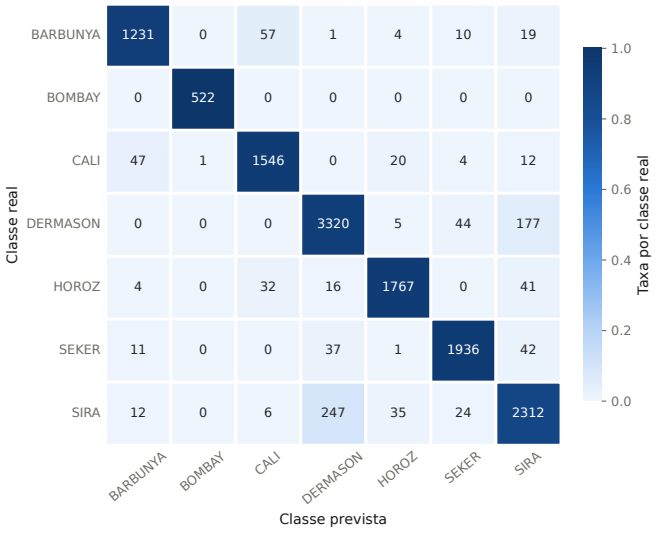


Figura 27: Matriz de confusão com as previsões das dez partições reunidas.

Tabela 22: MLP e regressão logística nas mesmas partições.

Modelo	Perda	Acurácia	Medida-F	dp Medida-F
MLP	0,1845	0,9329	0,9436	0,0085
Regressão logística	0,2190	0,9246	0,9365	0,0080

c. Análise e discussão

Resultado médio e variabilidade. A Medida-F é de $0{,}9436 \pm 0{,}0085$ (variância de 0,00007), a acurácia é de $0{,}9329 \pm 0{,}0101$ e a perda, de $0{,}1845 \pm 0{,}0260$. Os valores de Medida-F vão de 0,9291 a 0,9572.

Robustez. A rede se comporta de modo consistente: nenhuma partição fica longe das demais, e o desvio é menor que 1% da média. Por outro lado, esse desvio é maior que toda a faixa de Medida-F entre as 30 topologias da Questão 3 (0,0062). Assim, a escolha de quais exemplos caem no teste pesa mais no resultado do que a escolha da topologia dentro da faixa estudada. O resultado no teste da Questão 6 (0,9359) está dentro da faixa e perto do limite inferior de um desvio (0,9351), o que confirma que aquela divisão era um pouco mais difícil que a média.

Flutuações. A perda de treino quase não muda entre partições (0,1561 a 0,1630), enquanto a de teste vai de 0,1447 a 0,2417. Na partição 6, a perda de teste é até menor que a de treino. A variação vem, portanto, de quais exemplos caem no teste, e o treinamento em si é estável. Quanto à causa, o provável é o número de exemplos das fronteiras entre classes parecidas presentes em cada partição, mais do que o desbalanceamento em si: a estratificação fixa as proporções, e a classe menor, Bombay, é quase sempre acertada (Medida-F de 0,9990). Essa explicação não foi testada partição a partição.

Erros por classe. A matriz reunida confirma a Questão 6. Sira tem a menor Medida-F (0,8826), e Sira e Dermason respondem pelas maiores confusões: 247 e 177 exemplos nos dois sentidos, seguidas por Barbunya e Cali (57 e 47).

Comparação com o modelo linear. A regressão logística chega a uma Medida-F de 0,9365 e perda de 0,2190. O ganho pareado da MLP é de $0{,}0070 \pm 0{,}0050$ na Medida-F, com vantagem em 8 das 10 partições. A MLP é melhor, com margem pequena, o que sugere que as fronteiras entre as classes são em boa parte quase lineares nesses atributos.

d. Conclusão da etapa

A rede final generaliza de forma consistente, com Medida-F em torno de 0,94 e pouca variação entre partições. A estimativa é levemente otimista: como o enunciado prevê, a configuração foi escolhida com dados que também entram no k-fold, inclusive o teste da Questão 6.

Duas melhorias parecem mais promissoras do que aumentar a rede: atributos ou amostras adicionais voltados à separação entre Sira e Dermason, e parada antecipada em conjunto com calibração das probabilidades, já que a perda se mostrou mais sensível que a Medida-F. São hipóteses que este estudo não testou.

9 Conclusão geral

A MLP aprendeu o problema com facilidade e chegou a uma Medida-F macro de $0{,}9436 \pm 0{,}0085$ em validação cruzada. Os principais achados de cada etapa foram:

- A inicialização dos pesos afetou pouco o resultado final, e a ReLU foi tão boa quanto a tanh e muito mais rápida que a logistic.
- A taxa de aprendizado e o momento definem a velocidade por meio da taxa efetiva $\eta/(1-m)$. Valores altos trocam velocidade por overfitting rápido e, no extremo, levam ao colapso da rede.
- A topologia teve efeito pequeno. A variação entre as 30 redes é menor que a variação entre partições dos dados.
- Mais dados continuaram reduzindo a perda em toda a faixa testada, com retorno decrescente em Medida-F a partir de cerca de 40% do treino.
- Dez atributos de forma substituem os 16 originais sem perda mensurável. Colunas de ruído causaram overfitting, e a importância por permutação engana quando os atributos são correlacionados.
- O critério de perda $\leq 0{,}001$ só foi atingido com LR = 0,1 ou maior: em cerca de 2.400 épocas na rede 50×50 (momento 0,9) e em menos de 400 na rede 100×100×100 (momento 0,9), sempre com forte overfitting. Nesta base, em que as classes se sobrepõem, ele mede a memorização do treino.

A regressão logística ficou a 0,0070 da MLP, e o erro restante se concentra entre Sira e Dermason. Os dados indicam, portanto, que o ganho adicional deve vir mais da informação de entrada do que de redes maiores.

Limitações

- Três seeds por configuração nas Questões 2, 3 e 5 detectam diferenças grandes, mas não resolvem empates pequenos. Por isso as seleções seguem regras fixadas de antemão, e várias escolhas são equivalentes na prática.
- As topologias têm camadas de mesmo tamanho, e LR e momento foram escolhidos em uma única topologia, sem reavaliação conjunta.
- Na Questão 4, a quantidade de dados varia junto com o número de atualizações dos pesos.

- A seleção final usa o teste, como pede o enunciado, e o k-fold usa a base inteira. Os resultados finais são, assim, levemente otimistas.
- Os tempos valem para uma única máquina e servem apenas para comparações relativas.

Referências

[1] M. Koklu e I. A. Ozkan. Multiclass classification of dry beans using computer vision and machine learning techniques. *Computers and Electronics in Agriculture*, 174:105507, 2020.

[2] Dry Bean Dataset. UCI Machine Learning Repository, 2020. `https://doi.org/10.24432/C50S4B`.

[3] F. Pedregosa et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[4] A. Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 3. ed. O'Reilly, 2022.